Práctica Naive Bayes - Parte 1

Validación de conocimiento de principios del modelo teórico usando Bag of Words

Se tienen las siguientes frases asociadas a personas que muestran una personalidad con alta y baja apertura a experiencias. Se desea identificar si la frase de Test es una frase que pertenece a la categoría Alta o Baja según la evidencia.

Construya un modelo de Clasificación Bayesiano con los siguientes datos, y luego indique a qué clase pertenece la frase de Test que aparece al final proporcionando los cálculos respectivos. Tome en cuenta todos los términos en los cálculos incluidos artículos y conjunciones. Aplique suavizado de Laplace en los cálculos.

Personalidad - Apertura a la Experiencia

Baja

- «Prefiero lo práctico y útil»
- «Mantengo mis hábitos conocidos»
- «Respeto tradiciones y reglas»
- «Prefiero estabilidad previsible»

Alta

- «Exploro teorías complejas y vanguardistas»
- «Busco romper la rutina y las tradiciones»
- «Busco siempre cosas poco convencionales»
- «Me encanta probar cosas totalmente nuevas»
- «Imagino mundos e ideas alternativas»
- «Veo los cambios como oportunidades»

Test Set:

S1 «prefiero los cambios y romper las reglas»
S2 «prefiero el cambio e ideas nuevas»
S3 «veo y prefiero lo útil y la estabilidad»

Parte 2

Creación y etiquetado del Data Set.

Asigne una etiqueta a las letras que aparecen asignadas a usted en las hojas A B y C

DISCLAIMER: ALGUNAS DE LAS LETRAS DE REGGAETON POR SU NATURALEZA PUEDEN RESULTAR OFENSIVAS Y APARECEN TAL CUAL SE ENCUENTRAN DISPONIBLES EN MEDIOS DIGITALES

Asigne una etiqueta a cada comentario asignado:
-2 (Seguro que es Balada) -1 (parece Balada) 1 (parece Reggaeton) 2 (seguro es Regaeton)

Luego de la Anotación mientras hacen el ejercicio 1, se asignará un valor de R a las letras que los evaluadores consideraron como Reggaeton y B a las baladas.

Parte 3

Con el dataset de canciones recopilado en la hoja siguiente escriba un programa para:

https://docs.google.com/spreadsheets/d/1-opJP041NA6_ovpSUZRIeFW8jJuFhDu2Uf1-eYC7nXw/edit?usp=sharing

1. Preprocesar los datos de las canciones dejando solo las palabras sin acentos como una bolsa de palabras en minúscula se deben eliminar todos los signos de puntuación dejando solo términos con letras de la ‘a’ a la ‘z’.
2. Crear el vocabulario a partir de las palabras en el corpus
3. Crear un modelo bayesiano de clasificación con suavizado de Laplace y usando los datos de “Entrenamiento” construidos en clase.
   Indique la validez del modelo utilizando una validacion cruzada (n5 crossfold validation)
   Ofrezca datos de calidad del modelo previo a la evaluación de testing.
   LUEGO DE VALIDAR SU MODELO HAGAN LA EVALUACIÓN SOBRE LOS DATOS DE TESTING

   Deben preprocesar los datos de testing de la misma forma que los de entrenamiento.

4. Con los datos que no han sido vistos por el modelo procedan a evaluar las frases del set de “Evaluación” para verificar las calidad del calificador en términos de: accuracy promedio, precisión promedio, recall promedio, f1 promedio.